1 2 9 0

UNIVERSIDADE D
COIMBRA

Tomás Ferreira & Eduardo Pereira

Classificação de Feijões Baseada em Atributos Morfológicos

Um Estudo Comparativo de Modelos de Machine Learning

Trabalho realizado no âmbito da unidade curricular de Machine Learning, do Mestrado em Inteligência Artificial

Novembro 2025

Conteúdo

1 Introduction **1**
1.1 Contextualização e Formulação do Problema 1
1.2 Descrição do Dataset 2

2 Metodologia **5**
2.1 Pré-processamento e Limpeza de Dados 5
2.2 Análise Exploratória e Preparação dos Dados 6
2.2.1 Label Encoding 11
2.3 Correlation & Redundancy Analysis 11
2.4 Importância das Features via ReliefF 12
2.5 Preparação dos Dados para Modelação 12
2.6 Treino e Avaliação de Modelos 13

3 Conclusão e Trabalho Futuro **19**

Lista de Figuras

2.1 Distribuição das classes no dataset após limpeza, evidenciando a predominância da classe White Haricot Bean. 6
2.2 Histogramas das seis features 7
2.3 Matriz de correlação entre features. 7
2.4 Distribuição das seis features por classe. 8
2.5 Gráficos de densidade das seis features por classe. 9
2.6 Pairplot das features. 10
2.7 Recall para Diferentes Tamanhos da Arvore 14
2.8 Tuning do k no KNN com todas as features 15
2.9 Tuning do k no KNN com features reduzidas 15

Lista de Tabelas

1.1 Exemplos de observações do conjunto de dados binary_beans_english.csv, ilustrando as variáveis preditivas e a variável-alvo. 2

2.1 Resultados — métricas globais por modelo. 16
2.2 Resultados — métricas da classe Mixed Beans. 16
2.3 Resultados — métricas da classe White Haricot. 16

Capítulo 1

Introduction

O presente documento tem como objetivo relatar o challenge desenvolvido no âmbito da unidade curricular de Machine Learning, do Mestrado em Inteligência Artificial. O projeto foca-se na aplicação e avaliação de técnicas de machine learning para a resolução de um problema de classificação binária.

Este capítulo enquadra o projeto, expõe os objetivos do trabalho e descreve o dataset que serve de base à análise subsequente.

1.1 Contextualização e Formulação do Problema

O presente estudo de caso insere-se no contexto da indústria de processamento e embalamento alimentar, especificamente na produção de misturas de leguminosas secas destinadas ao consumidor final. O cenário de negócio proposto assenta numa linha de produção automatizada que recebe múltiplas variedades de feijões que são posteriormente combinados e embalados.

O problema central surge da identificação de um risco para a segurança alimentar. Foi determinado que uma das variedades processadas, o feijão White Haricot Bean, possui um composto proteico que atua como alergénio para um segmento da população, enquanto as restantes variedades são consideradas seguras para consumo generalizado. A inclusão inadvertida de um único feijão White Haricot Bean no produto final constitui um evento de contaminação com potencial para consequências na saúde pública, para além de expor a empresa a responsabilidades legais. O desafio reside na necessidade de garantir a segregação desta variedade da linha de produção. Neste contexto, emerge a oportunidade de recorrer a técnicas de Machine Learning (ML) como solução para a deteção e segregação automatizada da variedade alergénica, White Haricot Bean.

O problema é definido como uma tarefa de classificação binária supervisionada, onde cada instância corresponde a um feijão caracterizado por atributos extraídos de imagens adquiridas durante o processo de produção. A variável resposta assume dois valores: White Haricot Bean, correspondente à variedade alergénica, e Mixed Other Beans, representando o conjunto de todas as restantes variedades

seguras. O objetivo consiste na construção de um classificador capaz de discriminar entre estas duas classes.

A natureza da aplicação impõe requisitos específicos ao desempenho do modelo. A minimização de falsos negativos assume prioridade, isto é, situações em que um feijão White Haricot Bean é incorretamente classificado como Mixed Other Beans, resultando na sua inclusão no produto final. Os falsos positivos, correspondentes à classificação de feijões seguros como White Haricot Bean, embora menos críticos do ponto de vista da segurança, representam custos operacionais associados à rejeição de produto conforme, devendo igualmente ser minimizados numa perspetiva de eficiência económica.

1.2 Descrição do Dataset

O conjunto de dados que serve de base a este estudo, designado binary_beans_english.csv, é um dataset sintético fornecido no contexto do desafio curricular. O dataset compreende medições morfológicas quantitativas de feijões secos individuais provenientes de múltiplas variedades cultivadas, sendo composto por 6000 observações, cada uma descrita por sete atributos.

Destes sete atributos, seis constituem as variáveis preditivas, todas de natureza quantitativa contínua (float64), representando medições morfológicas dos feijões. As variáveis preditivas compreendem Length, correspondente ao comprimento do feijão, Width, representando a sua largura, Area, que quantifica a área de projeção, Perimeter, medindo o perímetro, Roundness, que quantifica a circularidade da forma, e Compactness, que caracteriza a compacidade da forma. A sétima variável, designada Class, constitui o atributo-alvo, sendo uma variável categórica binária que assume os valores White Haricot Bean, identificando a classe alergénica de interesse, ou Mixed Other Beans, que agrupa as restantes variedades seguras. A Tabela 1.1 apresenta exemplos de observações do conjunto de dados, ilustrando a estrutura dos atributos preditivos e da variável-alvo para ambas as classes.

Tabela 1.1: Exemplos de observações do conjunto de dados binary_beans_english.csv, ilustrando as variáveis preditivas e a variável-alvo.

Length	Width	Area	Perimeter	Roundness	Compactness	Class
42.9	14.7	630.8	114.5	0.6	2.9	White Haricot Bean
38.4	14.0	526.6	106.1	0.5	2.7	Mixed Other Beans

Uma análise preliminar à integridade dos dados revelou a existência de valores omissos em múltiplas colunas, incluindo atributos preditivos e a variável-alvo. Das 6000 instâncias totais, verificou-se que apenas 5970 possuem label, determinando a necessidade de uma etapa de pré-processamento para tratamento adequado destes dados ausentes antes da fase de modelação. No que diz respeito à distribuição dos dados, considerando apenas as amostras com label, o conjunto de dados apresenta um desequilíbrio de classes. A classe White Haricot Bean representa aproximadamente 63.3% das amostras, correspondendo a 3779 ins-

tâncias, enquanto a classe Mixed Other Beans constitui os restantes 36.7%, totalizando 2191 instâncias. Este desequilíbrio é um fator relevante que será considerado na preparação dos dados e na avaliação de desempenho dos classificadores.

Capítulo 2

Metodologia

A resolução do problema de classificação binária segue um pipeline standard de ML, compreendendo pré-processamento de dados, análise exploratória, partição dos dados, treino de modelos, otimização de hiperparâmetros e avaliação. Este capítulo descreve cada uma destas etapas e fundamenta as decisões metodológicas adotadas.

2.1 Pré-processamento e Limpeza de Dados

A primeira etapa consistiu na preparação e limpeza do conjunto de dados, assegurando a qualidade e integridade dos dados que servirão de base à modelação. Conforme identificado na descrição do dataset, o ficheiro binary_beans_english.csv apresentava amostras com valores omissos, tanto em features como na variável target.

Dada a impossibilidade de utilizar observações sem label em tarefas de aprendizagem supervisionada, procedeu-se à remoção de todas as amostras sem label. Subsequentemente, aplicou-se o mesmo procedimento às instâncias remanescentes que continham missing values em alguma das features. No total, esta limpeza resultou na remoção de 190 linhas.

A decisão de remoção completa (listwise deletion) foi reforçada pela análise da distribuição destes valores: 105 das linhas removidas pertenciam à classe "White Haricot Bean"e 55 à classe "Mixed Other Beans". Esta abordagem foi considerada apropriada não só por representar uma proporção marginal de dados (cerca de 3%), mas também por contribuir para um ligeiro reequilíbrio do dataset, ao eliminar preferencialmente instâncias da classe maioritária ("White Haricot Bean"), conforme identificado na análise subsequente (Figura 2.1).

2.2 Análise Exploratória e Preparação dos Dados

Após a etapa de limpeza, que resultou num conjunto de dados sem valores omissos, foi conduzida uma análise exploratória de dados com o objetivo de caracterizar as propriedades estatísticas da label e das features, fundamentando as decisões de pré-processamento subsequentes.

A primeira análise incidiu sobre a distribuição da label para quantificar o *class imbalance* no *dataset* limpo. A Figura 2.1 ilustra a contagem de instâncias por classe.

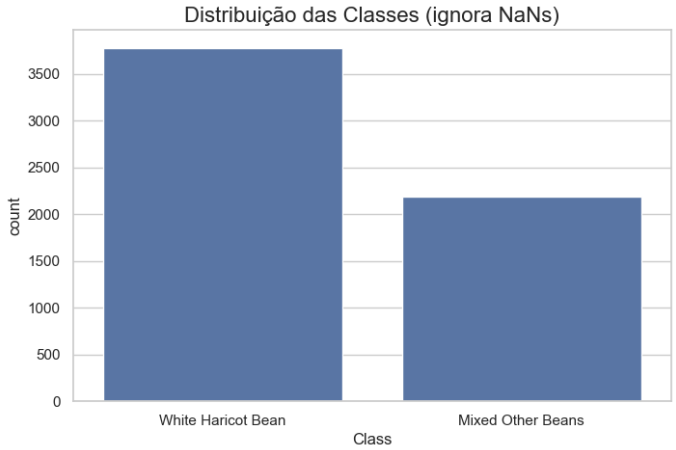

Figura 2.1: Distribuição das classes no dataset após limpeza, evidenciando a predominância da classe White Haricot Bean.

A visualização confirma que a classe White Haricot Bean representa aproximadamente 63% das observações, enquanto Mixed Other Beans constitui os restantes 37%, configurando um cenário de moderate class imbalance que influenciará a seleção de métricas de avaliação e estratégias de validação.

A análise das *features* foi conduzida através de histogramas que permitem caracterizar a forma das distribuições, identificar assimetrias e avaliar a presença de outliers. A Figura 2.2 apresenta a distribuição univariada de cada feature.

A análise de correlação entre features foi realizada através do cálculo da matriz de correlação, visualizada na Figur 2.3através de heatmap.

A matriz de correlação revela que as features relacionadas com dimensões físicas (Length, Width, Area, Perimeter) apresentam correlações positivas elevadas, resultado da interdependência geométrica destas medidas. As features derivadas Roundness e Compactness, que capturam propriedades de forma, apresentam correlações mais moderadas com as restantes variáveis, sugerindo que contribuem com informação complementar para a discriminação entre classes.

Para além da inter-relação entre variáveis, foi analisada a distribuição de cada feature em função da classe, com o intuito de aferir o seu poder discriminativo individual. A Figura 2.4 ilustra esta análise através de diagramas de boxplots.

A análise da Figura 2.4 revela que as quatro features dimensionais (Length, Width,

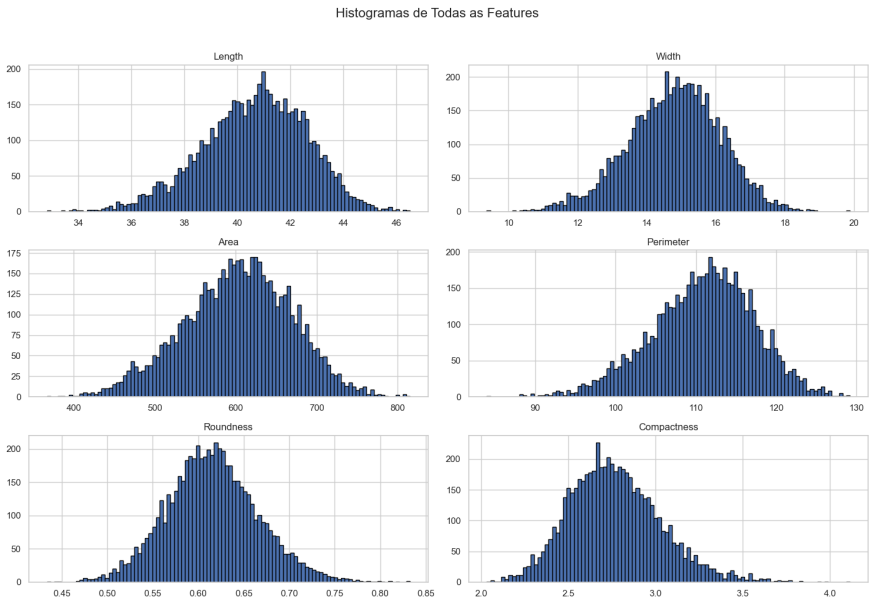

Figura 2.2: Histogramas das seis features

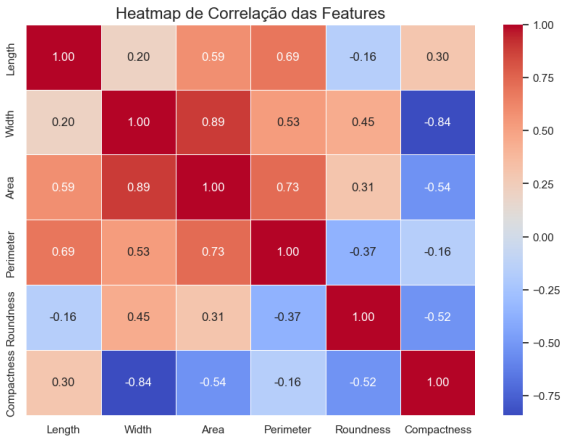

Figura 2.3: Matriz de correlação entre features.

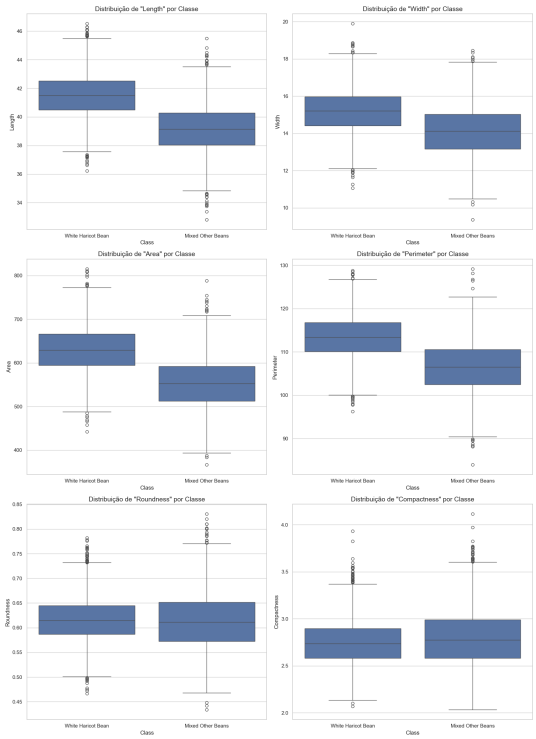

Figura 2.4: Distribuição das seis features por classe.

Area, Perimeter) demonstram uma separação estatística notória entre as duas classes. Em todas elas, a mediana da classe 'White Haricot Bean' é visivelmente superior à da classe 'Mixed Other Beans', indicando que a primeira classe é, em média, caracterizada por dimensões físicas superiores. Embora exista sobreposição nos quartis e a presença de outliers em ambas as classes, a distinta localização das tendências centrais sugere um elevado potencial discriminativo destas variáveis.

Pelo contrário, as features derivadas, que capturam propriedades de forma (Roundness e Compactness), apresentam distribuições largamente sobrepostas. As medianas e os intervalos interquartis (IQR) são muito similares para ambas as classes, com uma sobreposição quase total, sugerindo que estas variáveis, quando consideradas isoladamente, possuem um baixo poder de separação. Esta constatação, conjugada com a baixa correlação (Figura 2.3) destas features com as variáveis dimensionais, reforça a hipótese de que estas contribuem com uma fonte de informação distinta, cuja relevância deverá ser determinada na etapa de modelação.

Complementarmente à análise dos *boxplots*, a Figura 2.5 apresenta as densidades para cada feature, segmentadas por classe. Esta visualização permite uma análise da forma das distribuições e do grau de sobreposição entre as classes.

Os gráficos corroboram de forma inequívoca as observações anteriores. Para as features dimensionais (Length, Width, Area, Perimeter), é clara a separação das distribuições. As modas (picos de densidade) da classe 'White Haricot Bean' (azul) estão consistentemente localizadas em valores superiores aos das modas da classe 'Mixed Other Beans' (laranja). Embora exista uma zona de sobrepo-

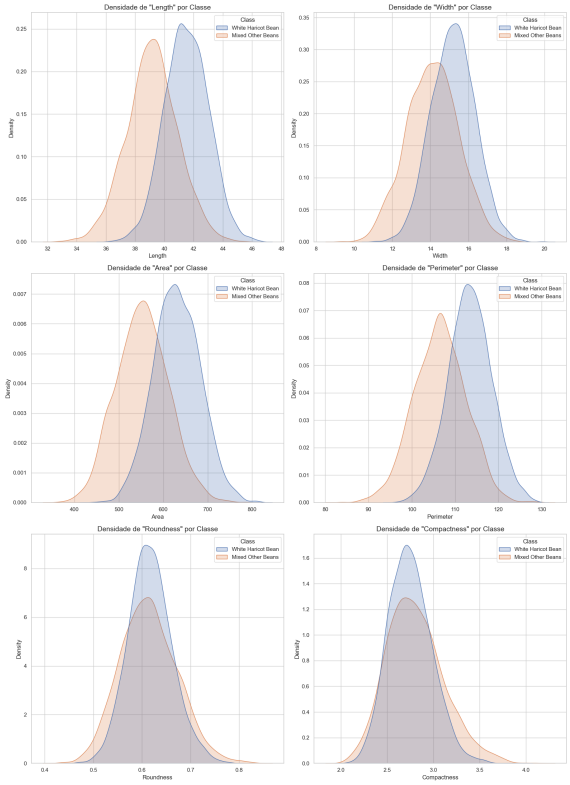

Figura 2.5: Gráficos de densidade das seis features por classe.

sição, a separação é estatisticamente significativa e confirma o potencial destas variáveis para a discriminação dos dois grupos. Em contrapartida, as features de forma, 'Roundness' e 'Compactness', evidenciam uma sobreposição muito acentuada.

Esta análise exploratória bivariada (feature vs. classe) é fundamental para as etapas subsequentes. Constata-se que as features operam em escalas muito distintas (e.g., 'Area' na casa das centenas, enquanto 'Compactness' se situa em unidades). Esta disparidade de escalas torna evidente a necessidade de aplicar técnicas de normalização antes do treino dos modelos.

Para consolidar a análise e investigar as interações bivariadas entre todas as features em simultâneo, foi criado uma matriz de gráficos de dispersão (pairplot), segmentada por classe, apresentada na Figura 2.6. Esta visualização complexa integra as distribuições de densidade univariadas (ao longo da diagonal) com as relações bivariadas (elementos fora da diagonal).

A análise dos elementos fora da diagonal (gráficos de dispersão) permite aprofundar as conclusões retiradas da matriz de correlação. Confirma-se visualmente que as quatro features dimensionais (Length, Width, Area, Perimeter) não só estão fortemente correlacionadas, como também demonstram uma separabilidade de classe muito elevada no espaço bivariado. Em qualquer par destas variáveis, os dados formam clusters visivelmente distintos, mas com alguma sobreposição, com a classe 'White Haricot Bean' (azul) a ocupar consistentemente a região de valores superiores para ambos os eixos, e a classe 'Mixed Other Beans' (laranja) a situar-se na região de valores inferiores. Inversamente, as relações que envolvem

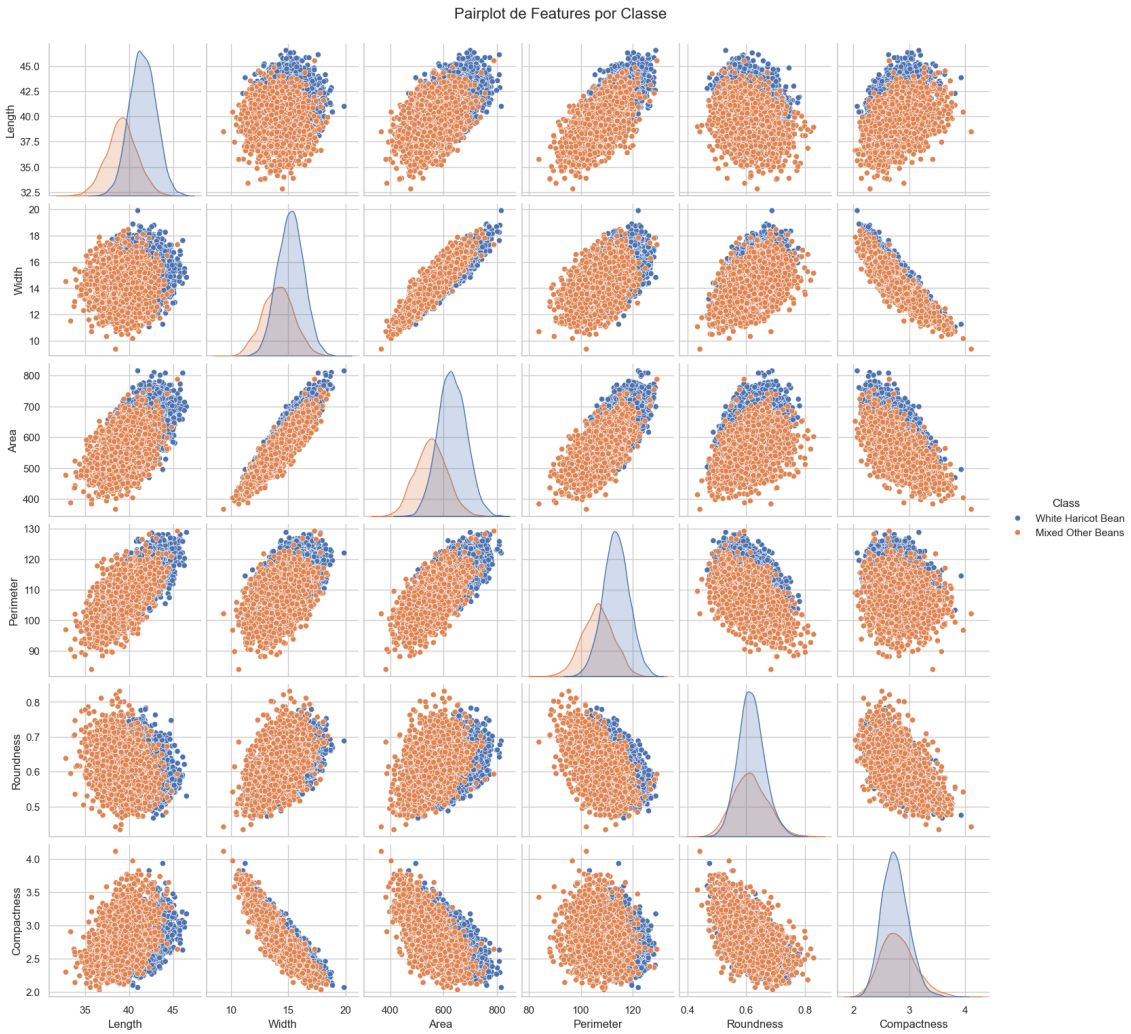

Figura 2.6: Pairplot das features.

as features de forma ('Roundness' e 'Compactness') confirmam o seu baixo poder discriminativo.

2.2.1 Label Encoding

A fase de preparação dos dados para a modelação iniciou-se com o tratamento da classe (label). Conforme o objetivo do desafio, o problema consiste numa tarefa de classificação binária: prever se um espécime de feijão pertence à classe "White Haricot Bean"ou não.

O conjunto de dados, após a remoção de quaisquer linhas com valores omissos, continha a coluna categórica "Class", que identificava as duas classes em formato de texto ("White Haricot Bean"e "Mixed Other Beans"). Para adequar estes dados aos algoritmos de classificação, foi necessário proceder à sua codificação numérica.

Para este efeito, foi criada uma nova coluna denominada "Target". Esta nova variável binária assume o valor inteiro 1 para representar a classe de interesse ("White Haricot Bean") e o valor 0 para a classe alternativa ("Mixed Other Beans"). Esta transformação converte eficazmente o problema num formato numérico binário, apto para a modelação.

Após a criação da nova variável "Target", a coluna "Class"original, que continha os valores textuais, tornou-se redundante e foi, por isso, removida do conjunto de dados.

2.3 Correlation & Redundancy Analysis

A fase inicial da análise metodológica focou-se na compreensão das inter-relações entre as variáveis do conjunto de dados. Para este fim, foi calculada a matriz de correlação de Spearman, adequando-se, assim, à natureza das distribuições das *features* observadas.

O objetivo desta análise, foi primeiramente, quantificar a associação entre cada feature preditora e a variável-alvo ("Target"), fornecendo uma indicação inicial do seu poder preditivo; e, em segundo lugar, detetar a presença de multicolinearidade, ou seja, correlações fortes entre as próprias features.

A análise revelou associações significativas. Notou-se uma correlação muito forte entre a 'Area' e a 'Width' ($\rho = 0.89$), bem como uma forte correlação negativa entre 'Compactness' e 'Width' ($\rho = -0.84$). Estas correlações elevadas sugerem um grau considerável de redundância, indicando que estas variáveis transportam informação similar. De forma similar, 'Area' e 'Perimeter' ($\rho = 0.73$) e 'Length' e 'Perimeter' ($\rho = 0.69$) também demonstraram correlações robustas.

No que diz respeito à variável-alvo, as features de dimensão 'Length' ($\rho = 0.58$) e 'Area' ($\rho = 0.57$) apresentaram as correlações mais relevantes, posicionando-se como potenciais preditores de importância. Em contraste, as features de forma,

como 'Roundness' ($\rho = 0.04$) e 'Compactness' ($\rho = -0.07$), evidenciaram uma correlação quase nula com o 'Target'. Estes resultados preliminares são cruciais para a subsequente etapa de seleção e engenharia de features.

2.4 Importância das Features via ReliefF

O objetivo desta etapa foi obter um ranking da relevância de cada feature para a classificação da variável-alvo. A aplicação deste algoritmo ao conjunto de dados produziu um ranking quantitativo da importância de cada variável. A feature 'Length' (Score = 0.0184) foi inequivocamente identificada como a mais relevante, distanciando-se das demais. Este resultado reforça a sua posição como um preditor primário, já sugerida na análise de correlação.

Seguiram-se, num grupo de relevância intermédia, as features 'Perimeter' (0.0130), 'Roundness' (0.0129) e 'Area' (0.0125). Um resultado particularmente notável foi a reavaliação da feature 'Roundness'. Enquanto a análise de correlação de Spearman, indicava uma associação quase nula com o 'Target' ($\rho = 0.04$), o ReliefF posicionou-a como a terceira variável mais importante. Isto sugere que 'Roundness', embora não linearmente correlacionada, possui um valor discriminativo significativo em interações não-lineares ou contextuais com outras features, algo que a análise de correlação simples não conseguiu capturar.

Por fim, 'Compactness' (0.0096) e 'Width' (0.0081) foram classificadas como as menos relevantes. Este resultado para a 'Width' é consistente com a análise de correlação, que a identificou como altamente redundante. O algoritmo ReliefF penalizou-a eficazmente, reconhecendo que a sua informação já estaria contida nas features de topo (como 'Length' e 'Area').

Este ranking quantitativo serviu de critério para a seleção do subconjunto final de features a ser utilizado na subsequente fase de modelação, visando otimizar o equilíbrio entre a complexidade do modelo e o seu potencial desempenho preditivo.

2.5 Preparação dos Dados para Modelação

Inicialmente, o conjunto de dados foi segregado na matriz de features (X) e no vetor-target (y). Seguindo a estratégia de avaliação de features, foram definidos dois conjuntos de variáveis preditivas para testar o impacto da sua seleção. O primeiro, Conjunto Completo (X), utilizou todas as seis variáveis morfológicas. O segundo, Conjunto Reduzido (X_r), constituiu uma versão otimizada, da qual foram removidas as duas features com menor relevância identificadas pelo algoritmo ReliefF: 'Compactness' e 'Width'.

Uma vez definidos estes dois conjuntos de dados, ambos (X/y e X_r/y_r) foram subsequentemente divididos em subconjuntos de treino (75%) e teste (25%). Um ponto essencial neste processo foi a aplicação da estratificação, dada a dis-

tribuição desequilibrada das classes identificadas na análise exploratória (aproximadamente 63% para 'White Haricot Bean' e 37% para 'Mixed Other Beans'). Esta técnica assegura que a proporção original das classes é mantida em todos os subconjuntos gerados, de forma a garantir que os modelos sejam treinados e avaliados de forma imparcial.

Por fim, foi aplicada a normalização dos dados. Este processo é essencial para colocar todas as features numa escala comum, assegurando que algoritmos sensíveis a esta (como KNN) não atribuam uma importância desproporcional a variáveis apenas por terem magnitudes numericamente maiores.

2.6 Treino e Avaliação de Modelos

A fase de treino e avaliação de modelos foi desenhada para endereçar o desafio central identificado na formulação do problema: a segregação rigorosa da variedade alergénica, "White Haricot Bean", da linha de produção. Dada a natureza do problema, onde a inclusão inadvertida de um único feijão alergénico no produto final constitui um evento de contaminação com potenciais consequências para a saúde pública, a estratégia de avaliação de modelos foi rigorosamente definida.

A métrica de desempenho crítica foi o recall da classe "White Haricot Bean", pois o objetivo é minimizar os falsos negativos (FN). Neste contexto, um FN é o cenário de maior risco: um feijão alergénico ("White Haricot") é classificado como seguro ("Mixed Other Beans"), resultando num risco de contaminação. Em contrapartida, um falso positivo (FP), um feijão seguro erradamente rejeitado como alergénico, representa um custo operacional. Este custo é considerado secundário e aceitável, dada a prioridade de proteger a saúde pública.

Para este efeito, foram comparados diversos algoritmos de classificação, incluindo DecisionTreeClassifier, KNeighborsClassifier (KNN) e LogisticRegression. Para cada modelo, procedeu-se ao ajuste de hiperparâmetros focado na maximização do recall da classe de interesse (White Haricot Beans). No caso do DecisionTreeClassifier, a profundidade da árvore (max_depth) foi otimizada, conforme ilustrado na Figura 2.7, identificando-se max_depth=3 como o valor ótimo que produziu um recall de 0.9325.

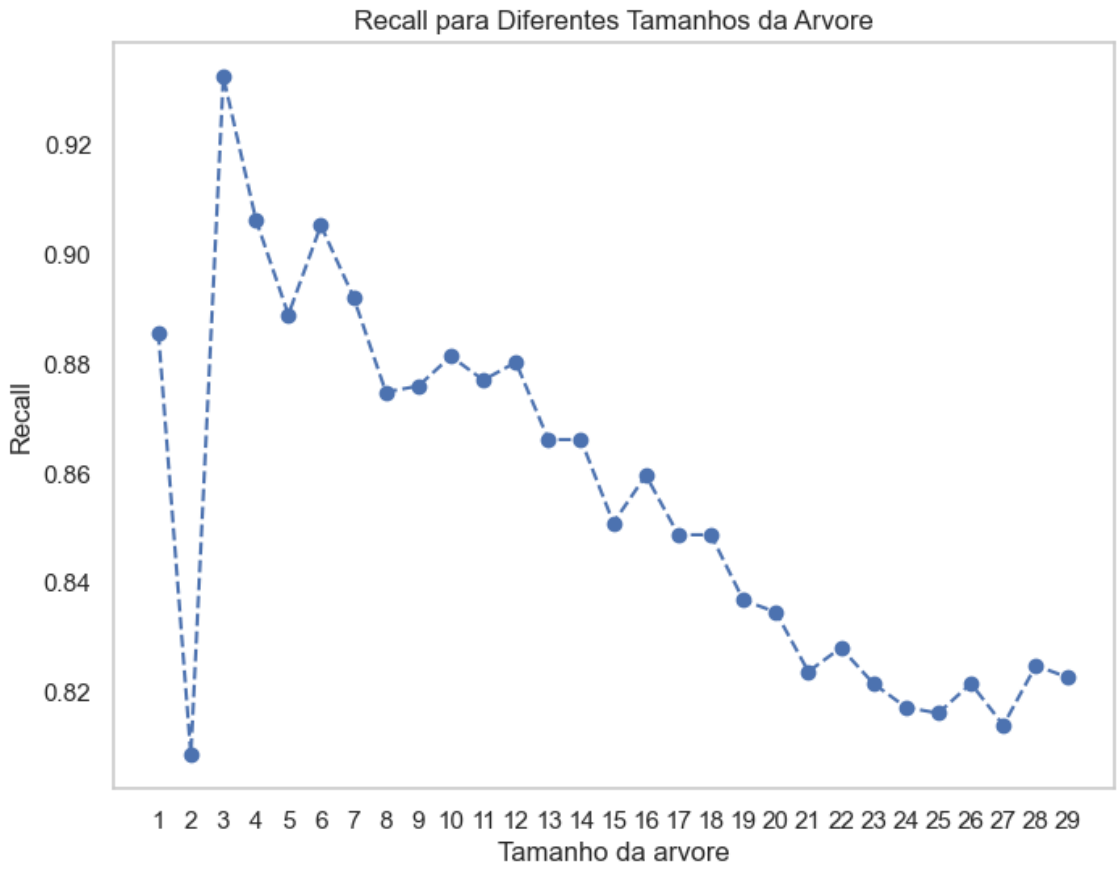

Figura 2.7: Recall para Diferentes Tamanhos da Arvore

Para o KNeighborsClassifier, foi realizado um tuning similar do número de vizinhos (k). Este processo, visível na Figura 2.8 para o conjunto completo de features e na Figura 2.9 para o conjunto reduzido, determinou que k=49 e k=35 eram os valores ótimos, respetivamente, atingindo recalls de 0.8977 e 0.9021.

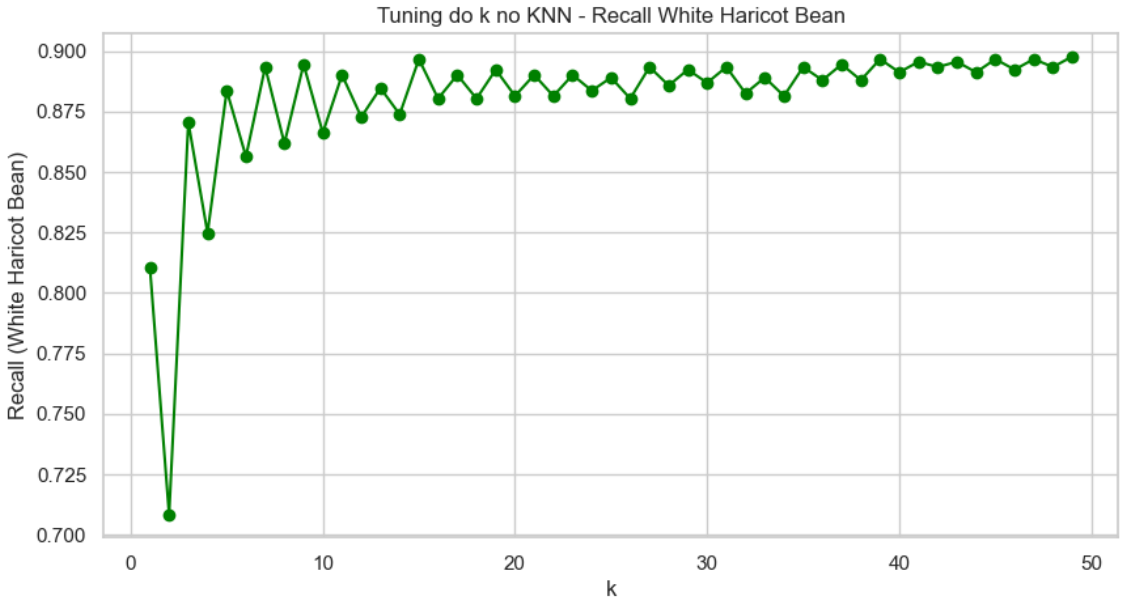

Figura 2.8: Tuning do k no KNN com todas as features

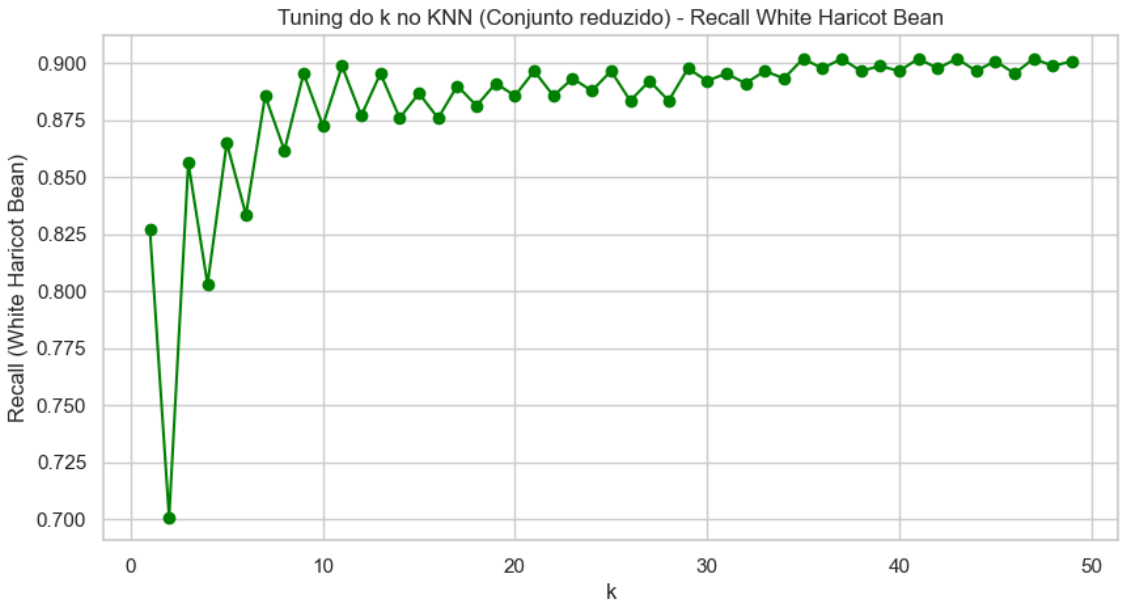

Figura 2.9: Tuning do k no KNN com features reduzidas

A avaliação comparativa de todas as abordagens testadas encontra-se consolidada nas tabelas subsequentes. A Tabela 2.1 apresenta as métricas globais para todos os modelos, enquanto a Tabela 2.2 e a Tabela 2.3 detalham o desempenho específico para as classes 'Mixed Beans' e 'White Haricot Bean', respetivamente.

A análise foca-se na Tabela 2.3, que contém a métrica crítica do projeto (recall da classe 'White Haricot Bean'). Esta análise demonstra que o modelo DecisionTreeClassifier (com max_depth=3) atingiu o desempenho mais elevado, alcançando um recall de 0.9325. Como visível na mesma tabela, este valor foi superior ao de todas as outras abordagens testadas, incluindo o KNN com features reduzidas (0.9021), a Logistic Regression (0.8836), e as combinações de KNN com PCA (máximo de 0.8988).

Modelo	Accuracy	Precision	Recall	F1-score
Decision Tree	0.810 048	0.813 972	0.810 048	0.801 542
Decision Tree (Features Reduzidas)	0.810 048	0.813 972	0.810 048	0.801 542
KNN	0.817 619	0.815 817	0.817 619	0.814 200
KNN (Features Reduzidas)	0.825 877	0.824 324	0.825 877	0.822 816
Logistic Regression	0.821 060	0.819 138	0.821 060	0.819 217
KNN + PCA(2)	0.805 919	0.803 873	0.805 919	0.801 639
KNN + PCA(3)	0.819 683	0.817 946	0.819 683	0.816 356

Tabela 2.1: Resultados — métricas globais por modelo.

Modelo	Precision	Recall	F1-score
Decision Tree	0.837 696	0.599 251	0.698 690
Decision Tree (Features Reduzidas)	0.837 696	0.599 251	0.698 690
KNN	0.794 311	0.679 775	0.732 593
KNN (Features Reduzidas)	0.804 772	0.694 757	0.745 729
Logistic Regression	0.780 738	0.713 483	0.745 597
KNN + PCA(2)	0.782 511	0.653 558	0.712 245
KNN + PCA(3)	0.796 943	0.683 521	0.735 887

Tabela 2.2: Resultados — métricas da classe Mixed Beans.

Modelo	Precision	Recall	F1-score
Decision Tree	0.800 187	0.932 535	0.861 307
Decision Tree (Features Reduzidas)	0.800 187	0.932 535	0.861 307
KNN	0.828 313	0.897 715	0.861 619
KNN (Features Reduzidas)	0.835 685	0.902 067	0.867 609
Logistic Regression	0.841 451	0.883 569	0.861 996
KNN + PCA(2)	0.816 286	0.894 450	0.853 583
KNN + PCA(3)	0.830 151	0.898 803	0.863 114

Tabela 2.3: Resultados — métricas da classe White Haricot.

A análise consolidada dos resultados permite concluir que o modelo DecisionTreeClassifier (com max_depth=3) se constitui como a solução mais robusta e adequada para o problema de negócio formulado.

A justificação desta escolha assenta na métrica prioritária de segurança alimentar: o recall da classe "White Haricot Bean". Conforme evidenciado pela Tabela 2.3, este modelo atingiu um recall de 0.9325, o valor mais elevado entre todas as arquiteturas testadas. Este resultado significa que o DecisionTreeClassifier é o modelo mais eficaz na identificação de feijões alergénicos, alinhando-se diretamente com o objetivo de minimizar os falsos negativos (FN) e o risco de contaminação.

Este desempenho superior na métrica de segurança implica um trade-off consciente. A Tabela 2.2 revela que este modelo apresenta o recall mais baixo para a classe "Mixed Beans"(0.599), o que indica uma taxa de falsos positivos (FP) mais elevada; no entanto, este é um trade-off aceitável. O custo operacional de rejeitar feijões seguros (FP) é considerado secundário face à prioridade de mitigar o risco crítico para a saúde pública (FN).

Capítulo 3

Conclusão e Trabalho Futuro

A conclusão central deste estudo é o trade-off entre a segurança e a viabilidade económica. O modelo DecisionTreeClassifier foi selecionado por ser o mais seguro, maximizando o recall da classe alergénica "White Haricot Bean"e minimizando o risco de contaminação.

Contudo, esta otimização gerou uma elevada taxa de falsos positivos, refletida no baixo recall da classe segura "Mixed Beans". Este resultado levanta dúvidas sobre a rentabilidade económica do modelo numa implementação industrial, dado o elevado custo associado ao desperdício de produto seguro.

Como trabalho futuro, a principal recomendação é o enriquecimento do dataset. As features atuais são insuficientes para separar as classes de forma eficiente. A adição de features de maior poder discriminativo, como a cor ou textura, é essencial para tentar reduzir os falsos positivos (aumentando a rentabilidade) sem comprometer a segurança.